VARGROUP

Sviluppare un Sistema IA di Caching Semantico e Dashboard FinOps

Estendere le funzionalità del Progetto OpenSource LiteLLM

Le sfide del mercato IA

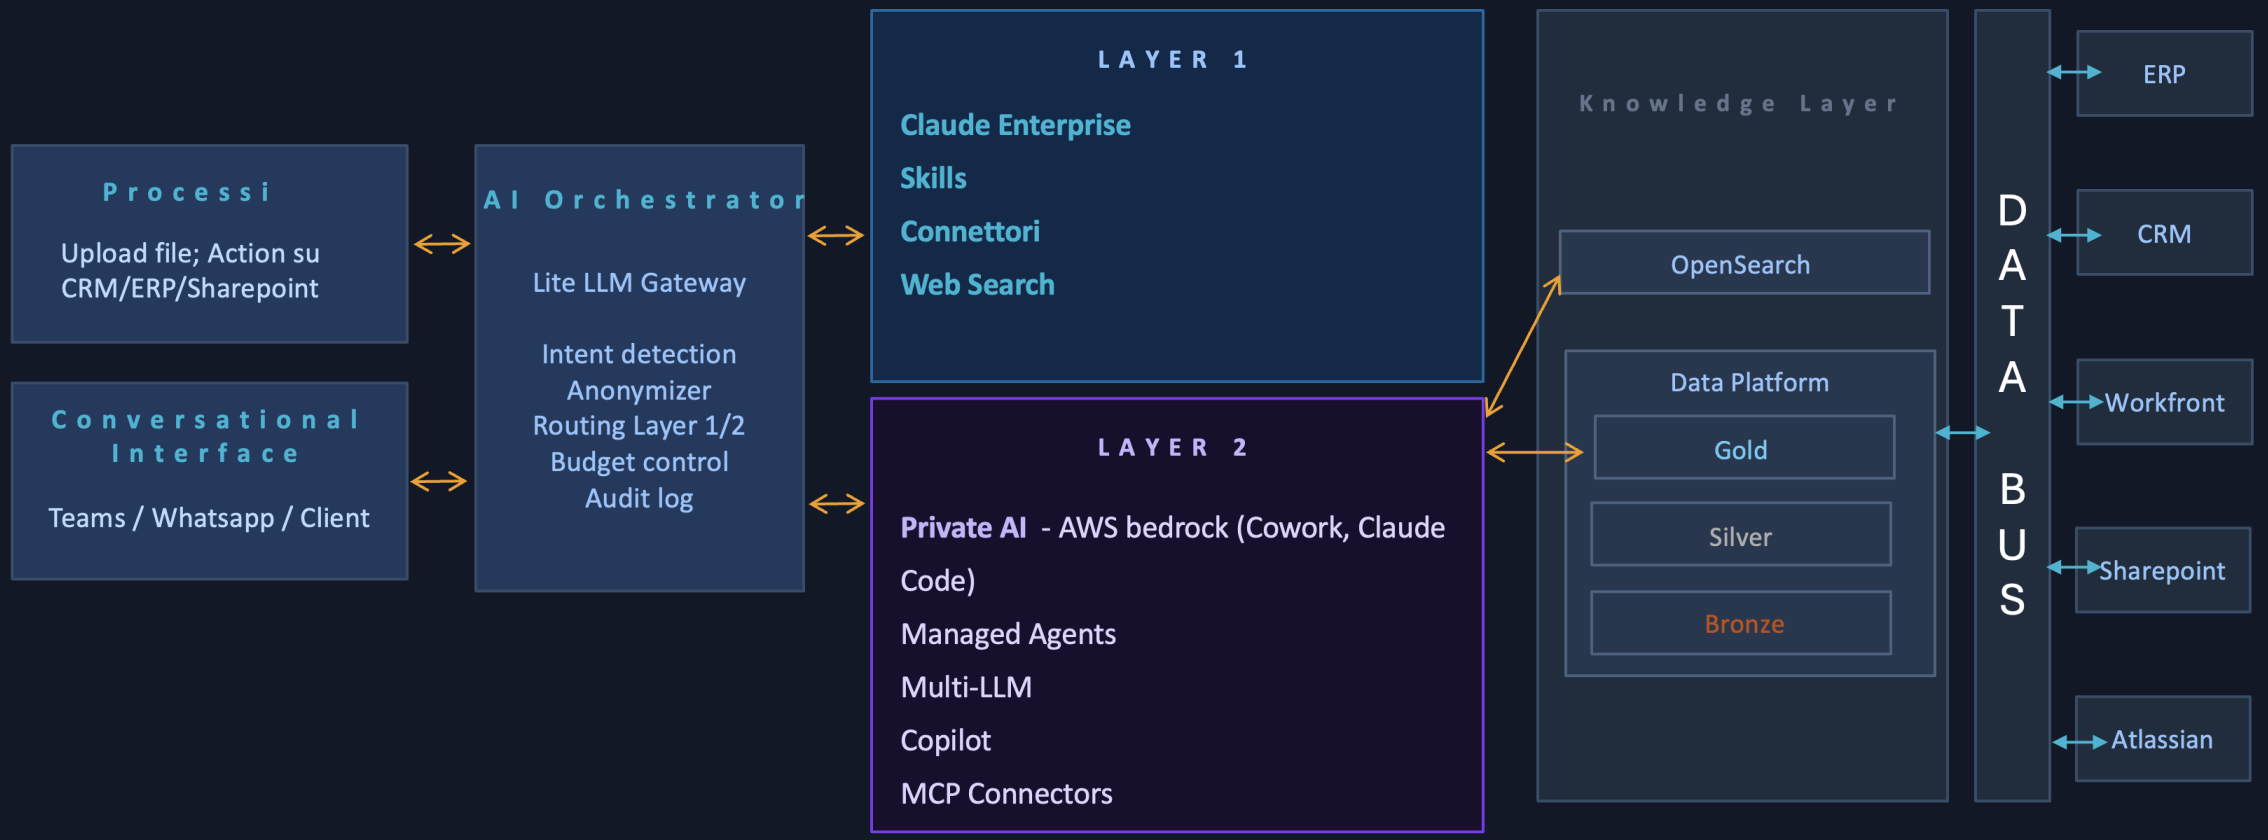
$200B+
mercato IA globale entro 2025

80%
delle query LLM semanticamente ridondanti

3×
crescita annua costi inferenza vs budget IT

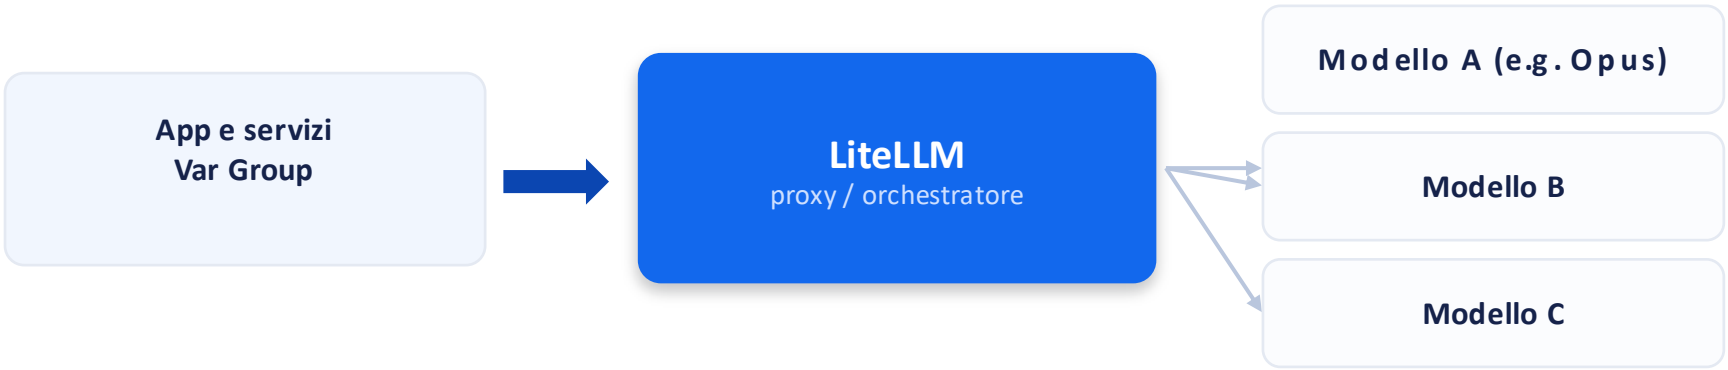
- Le aziende con progetti in produzione faticano a gestire i costi IA
- Le cache tradizionali (1) non riescono ad identificare azioni ripetute in azienda
- Non ci sono ancora sistemi evoluti per fornire viste granulari sui costi (2)
- I costi tipicamente si identificano solo con la fattura finale (2)

Il contesto Var Group



CONCETTO 5 · L'ORCHESTRATORE

LiteLLM: un unico "centralino" davanti a tutti i modelli



Cosa fa già bene

- Interfaccia unica, compatibile con lo standard OpenAI.
- Instrada le richieste tra più provider (routing).
- Gestisce chiavi e credenziali. Già in produzione in Var Group.

I due "buchi" che il progetto colma

1. Niente cache semantica —
si ripaga per domande equivalenti.

2. Niente FinOps —
nessuna visibilità, controllo o previsione dei costi.

Obiettivo del Progetto:

Estendere LiteLLM con due componenti originali che colmano i suoi limiti critici in produzione

01 Caching Semantico

Layer di cache basato su embedding e similarity search. Riconosce query semanticamente simili, restituisce la risposta cachata, logga token e latenza risparmiati.

Soglia di similarità configurabile, invalidazione TTL/versioning, persistenza su Redis o vector DB.

02 Dashboard FinOps

Servizio separato che aggrega i consumi per team / progetto / utente, calcola il risparmio reale dalla cache semantica, gestisce budget + alert, e forecasting della spesa mensile.

Aggiornamento near real-time, multi-tenancy, isolamento dati per team.

DELIVERABLE

Output Attesi dal Progetto

01

Architettura & ADR

Diagrammi, Architecture Decision Records, schema data model

02

Documento di Requisiti

Business requirements post design thinking + User Story Mapping

03

Diagrammi UML

Use Cases, diagrammi di sequenza e di componenti

04

MVP Funzionante End-to-End

Proxy + caching semantico + dashboard FinOps integrati

05

Test Automatici (coverage ≥70%)

Unit test + integration test con report di copertura

06

Repository Git + Bug Report

Codice sorgente versionato, documentazione, bug report post-collaudo

Tecnologie consigliate

Backend & Proxy

Python 3.10+
LiteLLM (base)
FastAPI / Flask
Docker + Docker Compose

1

IA Embedding

OpenAI text-embedding-3-small
sentence-transformers (open source)
Cosine similarity (numpy / scikit-learn)

2

Cache & Vector Store

Redis (cache + TTL)
Qdrant o pgvector (vector search)
PostgreSQL (metriche FinOps)

3

Dashboard & Frontend

React + Chart.js
Streamlit (alternativa rapida)
REST API JSON
Git / GitHub o Bitbucket

4

Vincoli del progetto

Processo

- Sessione di design thinking con il committente
- User Story Mapping e PoC di fattibilità tecnica prima dell'implementazione
- Standup periodici con referente Var Group

Architettura

- LiteLLM come proxy base (non reinventarlo)
- Logica originale sostanziale su cache semantica e FinOps
- Design modulare ed estendibile per future funzioni

Qualità

- Test coverage ≥ 70% del codice prodotto
- Separazione test deterministici vs valutazione probabilistica
- Multi-tenancy: dati isolati tra team/progetto

Materiali da condividere

PRIMA DELL'IMPLEMENTAZIONE

- Documento di requisiti di business (post design thinking)
- Diagrammi UML degli Use Cases
- Schema design del database / data model
- Piano di test di unità (target coverage ≥ 70%)
- PoC di fattibilità tecnologica

DOPO IL COLLAUDO (POST-LIVE)

- Bug Reporting (problemi riscontrati in fase di test)
- Codice sorgente su repository Git (GitHub / Bitbucket)
- Documentazione architettura e scelte tecniche (ADR)

Supporto Var Group al team:

Design thinking · Formazione sulle tecnologie · Sessioni di review · Repository Git condiviso

Per rimanere in contatto

Alessio Borgheresi

Email: alessio.borgheresi@vargroup.com

Stefano Dindo

Email: stefano.dindo@vargroup.com

Laura Ferretti

Email: laura.ferretti@vargroup.com

Michele Massaro

Email: michele.massaro@vargroup.com

Vi chiediamo di inviare una mail con oggetto: **SWE 2026 | <Oggetto della mail>**
Tutte le persone presenti devono essere in copia alla mail



VARGROUP